

CausalRAG – Tăng cường RAG bằng suy luận nhân quả

1. Mở đầu

1.1. Tổng quan về RAG

Retrieval-Augmented Generation (RAG) là một kiến trúc quan trọng cải thiện khả năng sinh của các mô hình ngôn ngữ lớn (LLM), nâng cao chất lượng phản hồi. Thay vì chỉ dựa vào tri thức đã được học trong quá trình huấn luyện, RAG truy hồi và sử dụng thông tin ngoài để xây dựng ngữ cảnh (context) phù hợp, từ đó giúp cải thiện độ chính xác, giảm hiện tượng ảo giác (hallucination) và tăng cường độ tin cậy của kết quả sinh ra. RAG không những áp dụng trong các hệ thống hỏi đáp mà còn có thể áp dụng trong các hệ thống tóm tắt văn bản dựa theo truy vấn (query-focused summarization).

1.2. Graph-based RAG

Các hướng tiếp cận như GraphRAG[1], LightRAG[2], LazyGraphRAG[3] đã mở rộng kiến trúc RAG bằng cách đưa vào biểu diễn quan hệ bằng đồ thị (graph), trong đó các thực thể và mối quan hệ giữa chúng được tổ chức thành các nút và cạnh. Các phương pháp này giúp hệ thống truy hồi được những ngữ cảnh có tính liên kết cao hơn, từ đó cải thiện độ chính xác của phản hồi, đồng thời hỗ trợ tốt hơn cho các tác vụ yêu cầu suy luận phức tạp.

Không chỉ có vậy, một số nghiên cứu gần đây tiếp tục mở rộng biểu thức tri thức đồ thị. Cụ thể, HyperGraphRAG[4] sử dụng siêu đồ thị (hypergraph) thay vì đồ thị thông thường, cho phép mô hình hóa các quan hệ nhiều bên (quan hệ n-ary) thay vì chỉ giới hạn ở quan hệ hai thực thể, từ đó phản ánh tốt hơn các mối liên quan phức tạp trong dữ liệu thực tế. Bên cạnh đó, OG-RAG[5] (Ontology-Grounded RAG) tích hợp ontology chuyên ngành giúp chuẩn hóa khái niệm, kiểm soát ngữ nghĩa và đảm bảo tính chính xác của tri thức, đặc biệt trong các lĩnh vực yêu cầu độ tin cậy cao như y tế hay pháp luật. PolyRAG[6] đưa vào cấu trúc kim tự tháp 3 tầng: ontology, đồ thị tri thức và các phân đoạn văn bản thô, giúp cân bằng giữa độ bao phủ và độ chính xác của truy hồi.

1.3. Hai vấn đề còn tồn tại

Mặc dù đạt được nhiều cải tiến, các hệ thống RAG hiện nay vẫn tồn tại hai vấn đề cốt lõi.


Thứ nhất, quá trình chia nhỏ văn bản (chunking) làm phá vỡ cấu trúc ngữ nghĩa và mạch lập luận tự nhiên của tài liệu gốc, dẫn đến việc các đoạn được truy hồi thiếu liên kết và không còn đảm bảo tính toàn vẹn ngữ cảnh.

Thứ hai, cơ chế truy hồi chủ yếu dựa trên *sự tương đồng về ngữ nghĩa* (semantic similarity) khiến hệ thống ưu tiên những nội dung “gần về mặt ngôn ngữ” hơn là “liên quan về mặt bản chất”, trong khi nhiều thông tin quan trọng lại gắn với *quan hệ nhân quả* chứ không biểu hiện trực tiếp qua sự tương đồng bề mặt. Điều này dẫn đến tình trạng phản hồi có vẻ liên quan nhưng không sâu, thiếu những chi tiết thiết yếu.

2. Tóm tắt phương pháp

Để giải quyết những vấn đề tồn tại trên, phương pháp CausalRAG[7] được đề xuất bởi Wang Nebo và các cộng sự. Trong khi RAG truyền thống chủ yếu lựa chọn ngữ cảnh dựa trên *mức độ tương đồng ngữ nghĩa*, tức là tìm kiếm những đoạn văn bản có nội dung tương đồng với truy vấn, thì CausalRAG chuyển hướng sang khai thác *suy luận nhân quả*, tập trung vào việc phát hiện và sử dụng các mối quan hệ nguyên nhân - kết quả tiềm ẩn trong dữ liệu.

CausalRAG cho phép sinh các phản hồi sâu sắc, chi tiết hơn, đồng thời làm giảm hiện tượng ảo giác và nâng cao tính đáng tin cậy.



Kiến trúc tổng quan của CausalRAG

2.1 Đồ thị nhân quả

Đồ thị nhân quả (causal graph) là một dạng biểu diễn tri thức dưới dạng đồ thị, trong đó các nút đại diện cho các thực thể, còn các *cạnh có hướng* biểu thị mối quan hệ *nguyên nhân - kết quả* giữa chúng. Khác với các đồ thị thông thường chỉ phản ánh sự liên kết hoặc tương quan, đồ thị nhân quả thể hiện rõ *chiều tác động* (từ nguyên nhân đến hệ quả), cho phép mô hình hóa và phân tích các chuỗi tác động trong hệ thống. Nhờ đặc tính này, đồ thị nhân quả hỗ trợ hiệu quả cho các tác vụ suy luận, giúp xác định không chỉ “cái gì liên quan” mà còn “vì sao nó xảy ra”, “nó dẫn đến điều gì”.

2.2. Lập chỉ mục

Trong giai đoạn lập chỉ mục (indexing), hệ thống chuyển đổi văn bản đầu vào từ dạng văn bản phi cấu trúc sang biểu diễn có cấu trúc dưới dạng đồ thị. Cụ thể, các thực thể hoặc khái niệm quan trọng trong văn bản được trích xuất thành các nút, còn các mối quan hệ giữa chúng được biểu diễn dưới dạng cạnh. Đồ thị này được xây dựng nhờ dùng LLM trích xuất từ văn bản đầu vào và được kiểm soát nhờ tri thức của chuyên gia.

Sau khi xây dựng đồ thị, các thành phần này tiếp tục được mã hóa thành vector thông qua mô hình embedding và lưu trữ trong cơ sở dữ liệu vector. Cách tiếp cận này không chỉ giúp bảo toàn thông tin quan hệ trong dữ liệu mà còn tạo điều kiện cho việc truy hồi hiệu quả ở bước sau.

Câu truy vấn được người dùng cung cấp cùng văn bản cũng được mã hóa thành vector embedding ngay giai đoạn này để chuẩn bị cho so khớp về sau. Toàn bộ giai đoạn lập chỉ mục này được tiến hành trước và độc lập nhằm đảm bảo giảm thiểu thời gian thực hiện truy vấn.

2.2. Thực hiện truy vấn

Bước 1: Truy hồi k nút có khoảng cách ngữ nghĩa gần nhất với truy vấn

Bước 2: Trên đồ thị đã xây dựng lúc lập chỉ mục, mở rộng s bước từ k nút đã truy hồi

Bước 3: Sử dụng LLM để phân tích các chuỗi nhân quả quan trọng giữa các nút và cạnh đã có ở bước 2, và xây dựng một *đồ thị nhân quả*.

Bước 4: Sử dụng LLM tóm tắt thông tin truy hồi được thành một *bản tóm tắt nhân quả* tập trung vào các phần trực tiếp trả lời truy vấn.

Bước 5: Truyền bản tóm tắt nhân quả và truy vấn cho LLM sinh câu trả lời đầu ra.

3. Kết quả

Kết quả thực nghiệm trên tập dữ liệu học thuật OpenAlex cho thấy CausalRAG mang lại những cải thiện rõ rệt so với các phương pháp RAG truyền thống và các biến thể khác dựa trên đồ thị. Cụ thể, hệ thống đạt độ tin cậy cao hơn, thể hiện qua việc câu trả lời bám sát hơn với nội dung nguồn và ít sai lệch. Đồng thời, độ chính xác của ngữ cảnh được cải thiện vượt trội nhờ cơ chế truy hồi dựa trên quan hệ nhân quả giúp loại bỏ các thông tin không thực sự liên quan. Một hệ quả quan trọng khác là sự giảm đáng kể hiện tượng ảo giác, khi mô hình được cung cấp ngữ cảnh có cấu trúc và mang tính logic rõ ràng, từ đó hạn chế việc suy diễn thiếu căn cứ.

4. Hạn chế và hướng phát triển

Mặc dù mang lại nhiều cải tiến, CausalRAG vẫn tồn tại một số hạn chế nhất định. Trước hết, phương pháp này phụ thuộc đáng kể vào khả năng của LLM trong việc xây dựng và suy luận trên các quan hệ nhân quả, do đó chất lượng kết quả có thể bị ảnh hưởng nếu mô hình chưa đủ mạnh hoặc thiếu kiến thức chuyên sâu trong một số lĩnh vực. Bên cạnh đó, việc gọi LLM nhiều lần cũng làm *gia tăng chi phí tính toán và thời gian xử lý*, gây khó khăn cho việc triển khai ở quy mô lớn hoặc trong các hệ thống yêu cầu độ trễ thấp.

Trong tương lai, các hướng phát triển tiềm năng bao gồm việc *tối ưu hóa hiệu năng* của toàn bộ pipeline nhằm giảm chi phí và cải thiện tốc độ, cũng như nghiên cứu các cơ chế *truy hồi thích ứng (adaptive retrieval)*, cho phép hệ thống tự động điều chỉnh phạm vi truy hồi (ví dụ như số lượng nút hoặc độ sâu mô rộng) tùy theo độ phức tạp của truy vấn. Những cải tiến này hứa hẹn sẽ giúp CausalRAG trở nên linh hoạt và hiệu quả hơn trong các ứng dụng thực tế.

6. Kết luận

CausalRAG đại diện cho một bước chuyển quan trọng trong thiết kế hệ thống RAG, khi thay đổi tiêu chí truy hồi từ *tương đồng ngữ nghĩa (similarity)* sang *liên kết nhân quả (causality)*. Nhờ đó, hệ thống không chỉ tìm được các thông tin liên quan bề mặt mà còn nắm bắt được bản chất logic và mối quan hệ nguyên nhân - kết quả giữa các yếu tố trong dữ liệu. Nhờ đó, hệ thống cho câu trả lời trở nên chính xác, sâu sắc và có khả năng giải thích tốt hơn, đặc biệt trong các bài toán yêu cầu kiến thức và lập luận phức tạp.

Nguồn tham khảo

1. From Local to Global: A GraphRAG Approach to Query-Focused Summarization (Edge et al., 2024)
2. LightRAG: Simple and Fast Retrieval-Augmented Generation (Guo et al., 2024)
3. LazyGraphRAG sets a new standard for quality and cost (Brenda Potts, 2024)
4. HyperGraphRAG: Retrieval-augmented generation via hypergraph-structured knowledge representation (Luo et al., 2025)
5. OG-RAG: Ontology-grounded retrieval-augmented generation for large language models (Sharma et al., 2025)
6. Knowledge PyramidConstruction for Multi-Level Retrieval-Augmented Generation (Chen et al., 2025)
7. CausalRAG: Integrating Causal Graphs into Retrieval-Augmented Generation (Wang et al., 2025)